

Contexto:

Un Arquitecto de IA de nivel empresarial debe balancear la alta precisión en el rendimiento de los modelos con la viabilidad financiera de las soluciones desplegadas. La API de Anthropic habilita mecanismos avanzados para el procesamiento de grandes volúmenes de información de manera rentable. Este documento establece el diseño técnico para la auditoría masiva de contratos mediante dos optimizaciones clave:

- Prompt Caching: Almacenamiento en caché del prefijo estático del sistema (instrucciones, políticas y contexto) reduciendo el costo de lectura de tokens recurrentes hasta en un 90%.
- Message Batches API: Procesamiento asíncrono para cargas de trabajo masivas no urgentes (ventana de ejecución de hasta 24 horas) otorgando un 50% de descuento automático en todos los tokens consumidos.

1 - Plantilla de Prompt Profesional (rol y objetivo específico) :

Eres un Auditor Financiero y Legal de élite especializado en análisis de riesgos contractuales. Tu objetivo es auditar contratos corporativos frente a la política de cumplimiento de la empresa y detectar cláusulas abusivas, penalizaciones financieras o riesgos de responsabilidad civil.

POLÍTICA CORPORATIVA Y REGLAS DE NEGOCIO (MARCO DE REFERENCIA ESTÁTICO):

1. Límite de responsabilidad: Ninguna cláusula debe superar el 100% del valor total del contrato.
2. Jurisdicción: Debe someterse exclusivamente a los tribunales de la Ciudad de México.
3. Términos de Pago: Máximo 60 días naturales. Cualquier interés moratorio superior al 1.5% mensual debe ser rechazado.
4. Propiedad Intelectual: Toda creación derivada durante la prestación de servicios pertenece al Cliente sin excepción.

DIRECTRICES ESTRUCTURALES Y RAZONAMIENTO:

- Piensa paso a paso dentro de las etiquetas de "pensamiento" antes de ofrecer tu conclusión final.
- Desglosa cada cláusula identificada, evalúala contra la política corporativa e indica si es APROBADA o RECHAZADA.
- Si detectas una incongruencia, explica el impacto económico potencial.
- Tu respuesta final debe ir delimitada en la etiqueta "dictamen final"

2 - Delimitación de variables dinámicas:

Variable “Contrato a analizar”: Representa la única entrada dinámica en cada llamada al modelo a partir de los archivos PDF procesados.

3 - Modelo de flujo por lotes (Message Batches API):

El flujo asíncrono optimizado procesa lotes masivos de contratos en períodos de baja demanda computacional siguiendo cuatro fases operativas:

- Extracción y Formateo:
- Despacho vía Batch API: Envío del lote completo mediante
- Procesamiento Distribuido: Ejecución de peticiones en la infraestructura de Anthropic dentro de una ventana garantizada de 24 horas.
- Resultados: Recuperación automática de respuestas y almacenamiento en la Base de datos de la empresa.

4 - Cálculo matemáticamente el beneficio económico:

- Volumen de trabajo: Procesamiento de 500 contratos extensos.
- Modelo de IA: Claude 3.5 Sonnet.
- Desglose de Tokens por Solicitud: Prefijo Estático (4,000 tokens) | Input Dinámico (6,000 tokens) | Output Generado (1,000 tokens).
- Tarifas Oficiales Claude 3.5 Sonnet: Input Base: \$3.00/MTok | Batch Input: \$1.50/MTok | Cache Write: \$3.75/MTok | Cache Read Batch: \$0.15/MTok | Output Base: \$15.00/MTok | Output Batch: \$7.50/MTok.

Enfoque convencional: (llamadas síncronas, sin caching, sin batch):

CONCEPTO	TOKENS / SOLICITUD	TOTAL TOKENS (500 req)	PRECIO / MTok	COSTO TOTAL (USD)
input total	10.000	5.000.000	\$3	\$15
output total	1.000	500.000	\$15	\$7.5
costo total procesamiento convencional				\$22.50 USD

Enfoque optimizado: (Prompt caching + Message batches API):

CONCEPTO	TOKENS / SOLICITUD	TOTAL TOKENS (500 req)	PRECIO / MTok	COSTO TOTAL (USD)
Cache write (1ra ejecución)	4.000 (1 vez)	4.000	\$3.75	\$0.015
Cache Read (499 ejecuciones batch)	4.000 (x499)	1.996.000	\$0.15	\$0.300
input dinámico (batch)	6.000	3.000.000	\$1.5	\$4.500
output Total	1.000	500.000	\$7.50	\$3.750
Costo total Procesamiento Optimizado				\$8.565 USD

Tablero de impacto económico:

COSTO SIN OPTIMIZAR \$22.50 USD / 500 contratos	COSTO CON OPTIMIZACIÓN \$8.57 USD / 500 contratos	AHORRO DIRECTO 61.9% reducción de costos
---	---	--