

DISEÑO DE EFICIENCIA E INGENIERÍA DE PROMPTS RECURRENTES

Pre-Entrega 6: Optimización Financiera y Técnica de LLMs a Escala

ROL	PROVEEDOR LLM	ESPECIALIDAD
Arquitecto de IA / Lead Prompt Engineer	Anthropic (Claude 3.5 Sonnet / Haiku)	Prompt Caching & Message Batches API

1. Contexto y Objetivos de Arquitectura

Un Arquitecto de IA de nivel empresarial debe balancear la alta precisión en el rendimiento de los modelos con la viabilidad financiera de las soluciones desplegadas. La API de Anthropic habilita mecanismos avanzados para el procesamiento de grandes volúmenes de información de manera rentable. Este documento establece el diseño técnico para la auditoría masiva de contratos mediante dos optimizaciones clave:

- Prompt Caching:** Almacenamiento en caché del prefijo estático del sistema (instrucciones, políticas y contexto) reduciendo el costo de lectura de tokens recurrentes hasta en un 90%.
- Message Batches API:** Procesamiento asíncrono para cargas de trabajo masivas no urgentes (ventana de ejecución de hasta 24 horas) otorgando un 50% de descuento automático en todos los tokens consumidos.

2. Diseño Técnico de Prompts Avanzados con Control de Caché

Para estructurar el prompt de forma óptima, se divide el mensaje en un bloque de **Prefijo Estático** (guardado en caché) y un bloque de **Variables Dinámicas**. Esta separación minimiza la fluctuación de tokens y asegura el cumplimiento del umbral mínimo de activación de caché (1,024 tokens en Claude 3.5 Sonnet).

2.1 Estructura del Prompt en Formato API JSON

```
{
  "model": "claude-3-5-sonnet-20241022",
  "max_tokens": 1500,
  "system": [
    {
      "type": "text",
      "text": "ROL Y OBJETIVO:
Eres un Auditor Financiero y Legal de élite especializado en análisis de riesgos contractuales. Tu
objetivo es auditar contratos corporativos frente a la política de cumplimiento de la empresa y
detectar cláusulas abusivas, penalizaciones financieras o riesgos de responsabilidad civil.

POLÍTICA CORPORATIVA Y REGLAS DE NEGOCIO (MARCO DE REFERENCIA ESTÁTICO):
1. Límite de responsabilidad: Ninguna cláusula debe superar el 100% del valor total del contrato.
2. Jurisdicción: Debe someterse exclusivamente a los tribunales de la Ciudad de México.
3. Términos de Pago: Máximo 60 días naturales. Cualquier interés moratorio superior al 1.5% mensual
debe ser rechazado.
4. Propiedad Intelectual: Toda creación derivada durante la prestación de servicios pertenece al
Cliente sin excepción.

DIRECTRICES ESTRUCTURALES Y RAZONAMIENTO:
- Piensa paso a paso dentro de las etiquetas <pensamiento> antes de ofrecer tu conclusión final.
- Desglosa cada cláusula identificada, evalúala contra la política corporativa e indica si es APROBADA
o RECHAZADA.
- Si detectas una incongruencia, explica el impacto económico potencial.
- Tu respuesta final debe ir delimitada en la etiqueta <dictamen_final>.",
      "cache_control": { "type": "ephemeral" }
    }
  ]
}
```

```

    }
  ],
  "messages": [
    {
      "role": "user",
      "content": "Por favor analiza el siguiente contrato adjunto:

<contrato_dinamico>
{{CONTRATO_A_ANALIZAR}}
</contrato_dinamico>"
    }
  ]
}

```

2.2 Delimitación de Variables Dinámicas y Seguridad

- **Variable {{CONTRATO_A_ANALIZAR}}:** Representa la entrada única inyectada dinámicamente en cada llamada al modelo a partir de los archivos PDF procesados.
- **Encapsulamiento XML (<contrato_dinamico>):** Previene vulnerabilidades de *Prompt Injection* al aislar el contenido suministrado por el usuario de las instrucciones del sistema guardadas en caché.

3. Mitigación de Alucinaciones mediante Razonamiento Paso a Paso (CoT)

Para mitigar alucinaciones y errores lógicos en decisiones contractuales de alta dirección, se impone un proceso de razonamiento explícito estructurado (*Chain of Thought*) previo a la entrega del dictamen.

Ejemplo de Salida Forzada (CoT):

```

<pensamiento>
1. Análisis de Cláusula de Pago: Se especifica pago a 90 días con interés moratorio del 3% mensual.
2. Evaluación vs. Política:
  - Política permite max 60 días (Incumple).
  - Política permite max 1.5% moratorio (Incumple).
3. Cálculo de impacto: El exceso de 30 días genera costo financiero por financiamiento, más
sobrecosto del 100% en tasa moratoria.
</pensamiento>

<dictamen_final>
ESTADO: RECHAZADO
DESVIACIONES DETECTADAS:
1. Cláusula 4.2 (Términos de pago): Incompatible con Política Art. 3 (Exceso de 30 días).
2. Cláusula 4.5 (Interés moratorio): Excede el límite de la empresa en un 1.5% mensual.
</dictamen_final>

```

4. Modelo de Flujo por Lotes (Message Batches API)

El flujo asíncrono optimizado procesa lotes masivos de contratos en periodos de baja demanda computacional siguiendo cuatro fases operativas:

1. **Extracción y Formateo:** Lectura de archivos fuente y generación de un dataset estructurado en formato `.jsonl` con las solicitudes formateadas.
2. **Despacho vía Batch API:** Envío del lote completo mediante el endpoint dedicado `/v1/messages/batches`.
3. **Procesamiento Distribuido:** Ejecución de peticiones en la infraestructura de Anthropic dentro de una ventana garantizada de 24 horas.

4. **Consumo de Resultados:** Recuperación automatizada de respuestas y almacenamiento en la base de datos analítica de la organización.

5. Matriz Analítica de Ahorro de Costos y Tokens

5.1 Parámetros del Caso de Negocio

- **Volumen de trabajo:** Procesamiento de **500 contratos extensos**.
- **Modelo de IA:** Claude 3.5 Sonnet.
- **Desglose de Tokens por Solicitud:** Prefijo Estático (4,000 tokens) | Input Dinámico (6,000 tokens) | Output Generado (1,000 tokens).
- **Tarifas Oficiales Claude 3.5 Sonnet:** Input Base: \$3.00/MTok | Batch Input: \$1.50/MTok | Cache Write: \$3.75/MTok | Cache Read Batch: \$0.15/MTok | Output Base: \$15.00/MTok | Output Batch: \$7.50/MTok.

5.2 Tablas Comparativas Financieras

A. Enfoque Convencional (Llamadas Síncronas, Sin Caching, Sin Batch)

Concepto	Tokens / Solicitud	Total Tokens (500 req)	Precio / MTok	Costo Total (USD)
Input Total	10,000	5,000,000	\$3.00	\$15.00
Output Total	1,000	500,000	\$15.00	\$7.50
COSTO TOTAL PROCESAMIENTO CONVENCIONAL				\$22.50 USD

B. Enfoque Optimizado (Prompt Caching + Message Batches API)

Concepto	Tokens / Solicitud	Total Tokens (500 req)	Precio / MTok	Costo Total (USD)
Cache Write (1ra ejecución)	4,000 (1 vez)	4,000	\$3.75	\$0.015
Cache Read (499 ejecuciones Batch)	4,000 (x499)	1,996,000	\$0.15	\$0.300
Input Dinámico (Batch)	6,000	3,000,000	\$1.50	\$4.500
Output Total (Batch)	1,000	500,000	\$7.50	\$3.750
COSTO TOTAL PROCESAMIENTO OPTIMIZADO				\$8.565 USD

5.3 Dashboard de Impacto Económico

COSTO SIN OPTIMIZAR	COSTO CON OPTIMIZACIÓN	AHORRO DIRECTO
\$22.50	\$8.57	61.9%
USD / 500 CONTRATOS	USD / 500 CONTRATOS	REDUCCIÓN DE COSTOS

Proyección Anual a Escala Corporativa:
Procesando un volumen proyectado de **50,000 contratos al mes**, la implementación de Prompt Caching combinado con Message Batches API reduce el gasto operativo anual en LLMs de **\$27,000 USD** a **\$10,278 USD**, generando un ahorro neto directo de **\$16,722 USD/año** sin comprometer el desempeño ni la calidad del análisis.